

MODELISATION STATISTIQUE

MODELE LINEAIRE

SIMPLE

AVEC R

Statistique – Econométrie – Data Science

Chapitre 1

REGRESSION LINEAIRE

- **Modèle linéaire Simple**
- Modèle linéaire multiple
- Analyse de la variance à 1 facteur ANOVA-1
- Analyse de la variance à deux facteurs ANOVA-n
- Analyse de la covariance ANCOVA

1. MODELE ECONOMIQUE VS MODELE ECONOMETRIQUE

1.1 Modèle économique

Selon Barbancho, un modèle est l'expression mathématique d'une certaine théorie économique. L'exemple de la loi psychologique fondamentale de Keynes est assez pertinent à cet effet. D'après cette loi, en moyenne et la plupart du temps lorsque le revenu d'un individu augmente, il augmente aussi sa consommation, mais dans une proportion moindre à l'augmentation de son revenu. Mathématiquement, si on note la consommation par C_t et le revenu par Y_t , cette loi peut être spécifiée comme suit :

$$C_t = \alpha_0 + \alpha_1 Y_t$$

[avec α_1 : propension marginale à consommer, $0 < \alpha_1 < 1$]

En général, le modèle spécifié par l'économiste est défini comme étant une maquette de la réalité ou d'un phénomène sous forme d'équations dont les variables sont des grandeurs économiques.

A ce sujet, Lester C. Thurow note ceci : « Les équations décrivent à quoi ressemblerait le monde réel s'il ressemblait à la théorie ».

1.2 Modèle économétrique

Toujours selon Barbancho, un modèle économétrique n'est autre chose qu'un modèle économique qui contient les spécifications nécessaires pour son application empirique. C'est donc le modèle économique auquel on ajoute un terme d'erreur ε_t .

$$C_t = \alpha_0 + \alpha_1 Y_t + \varepsilon_t$$

[Modèle spécifié par l'économetre]

La première partie de ce modèle [$\alpha_0 + \alpha_1 Y_t$] constitue sa **partie systématique** et la deuxième [ε_t] sa **partie stochastique** ou **aléatoire**.

Il convient de noter également que le terme d'erreur ε_t [bruit, perturbation ou aléa] dénote de la différence entre l'économiste et l'économetre. Il synthétise l'influence sur C_t [variable expliquée] de toutes les autres variables oubliées et des erreurs éventuelles de spécification de la forme fonctionnelle dans le modèle spécifié par l'économiste. De plus, sa présence dans le modèle rend les paramètres α_0 et α_1 inconnus, on ne sait plus les calculer, il faut donc les estimer.

1.3 principales méthodes de modélisation statistique

Les méthodes de modélisation statistique sont, en fait, très nombreuses. Nous citons ci-dessous les principales, sachant que la croissance considérable des masses de données enregistrées dans différents secteurs (internet, biologie à haut débit, marketing...), le besoin d'exploiter ces données sur le plan statistique, ainsi que les outils modernes de calcul ont donné naissance ces dernières années (disons depuis le début du XXI^e siècle) à de nombreuses méthodes, de plus en plus sophistiquées et, dans le même temps, de plus en plus "gourmandes" en temps calcul.

Dans les méthodes décrites ci-dessous, il y a presque toujours une variable privilégiée, en général appelée variable à expliquer, ou variable réponse, et notée Y (il s'agit d'une variable aléatoire). Le but est alors de construire un modèle permettant d'expliquer "au mieux" cette variable Y en fonction de variables explicatives observées sur le même échantillon.

a. Le modèle linéaire (gaussien) de base

À la fois le plus simple, le plus ancien et le plus connu des modèles statistiques, il englobe essentiellement :

- ✓ la régression linéaire simple et multiple,
- ✓ l'analyse de variance
- ✓ et l'analyse de covariance.

Dans ce modèle, les variables explicatives (régresseurs ou facteurs) ne sont pas aléatoires (elles sont à effets fixes). Pour pouvoir être exploité pleinement, ce modèle nécessite l'hypothèse de normalité des erreurs, donc de la variable à expliquer (hypothèse gaussienne).

b. Le modèle linéaire généralisé

Il généralise le précédent à deux niveaux :

- d'une part, la loi des erreurs, donc de la variable réponse, n'est plus nécessairement gaussienne, mais doit appartenir à l'une des lois de la famille exponentielle ;
- d'autre part, la liaison linéaire entre l'espérance de la variable réponse et les variables explicatives se fait à travers une fonction particulière appelée fonction lien (spécifiée a priori).

Ce modèle englobe différentes méthodes telles que :

- ✓ la régression logistique,
- ✓ la régression de Poisson, le modèle log-linéaire
- ✓ ou certains modèles de durée de vie.

c. Les modèles non linéaires

De façon très générale, il s'agit de modèles permettant d'expliquer la variable réponse (aléatoire) au moyen des variables explicatives (non aléatoires dans les modèles usuels), à travers une fonction quelconque, inconnue (on est donc en dehors du cadre du modèle linéaire généralisé). Cette classe de modèles est très vaste et relève, en général, de la statistique non paramétrique. Citons, à titre d'exemple :

- ✓ la régression non paramétrique,
- ✓ les GAM (Generalized Additive Models)
- ✓ et les réseaux de neurones.

d. Les modèles mixtes

On désigne sous ce terme des modèles permettant d'expliquer la variable aléatoire réponse au moyen de diverses variables explicatives :

- ✓ certaines étant aléatoires (on parle en général de **facteurs à effets aléatoires**) et intervenant dans la modélisation de la variance du modèle,
- ✓ d'autres ne l'étant pas (on parle de **facteurs à effets fixes**) et intervenant dans la modélisation de la moyenne.

On trouve ainsi des modèles linéaires gaussiens mixtes, des modèles linéaires généralisés mixtes et des modèles non linéaires mixtes.

e. Les modèles pour données répétées

On appelle données répétées, ou données longitudinales, des données observées au cours du temps sur les mêmes individus (en général, il s'agit de personnes ou d'animaux suivis dans le cadre d'une expérimentation médicale ou biologique). De façon claire, il est nécessaire de prendre en compte dans ces modèles une certaine dépendance entre les observations faites sur un même individu à différents instants. Les modèles linéaires ou linéaires généralisés, qu'ils soient standards ou mixtes, sont utilisés dans ce contexte.

f. Les modèles pour séries chronologiques

Les séries chronologiques sont les observations, au cours du temps, d'une certaine grandeur représentant un phénomène économique, social ou autre. Si données répétées et séries chronologiques ont en commun de rendre compte de l'évolution au cours du temps d'un phénomène donné, on notera que ces deux types de données ne sont pas réellement de même nature (dans une série chronologique, ce sont rarement des personnes ou des animaux que l'on observe).

Pour les séries chronologiques, on utilise des modèles spécifiques :

- ✓ **Modèles AR (Auto-Regressive, ou auto-régressifs),**
- ✓ **MA (Moving Average, ou moyennes mobiles),**
- ✓ **ARMA,**
- ✓ **ARIMA (I pour Integrated)...**
- ✓ **ARCH**
- ✓ **GARCH**

g. L'analyse discriminante et la classification

S'il est plus courant d'utiliser ces méthodes dans un contexte d'exploration des données plutôt que dans un contexte de modélisation, l'analyse discriminante et la classification peuvent tout de même être utilisées dans la phase de recherche d'un modèle permettant d'ajuster au mieux les données considérées. C'est en particulier le cas lorsque la variable réponse du modèle envisagé est de nature qualitative.

h. Les modèles par arbre binaire de régression et de classification


Ces méthodes (plus connues sous le nom de CART, pour Classification And Regression Trees) consistent à découper une population en deux parties, en fonction de celle des variables explicatives et du découpage en deux de l'ensemble de ses valeurs ou modalités qui expliquent au mieux la variable réponse. On recommence ensuite sur chaque sous-population ainsi obtenue, ce qui permet de définir, de proche en proche, un arbre binaire et de classer les variables explicatives selon l'importance de leur liaison avec la variable réponse (on parle d'arbre de régression en présence d'une variable réponse quantitative et d'arbre de classification en présence d'une variable réponse qualitative). De telles méthodes peuvent constituer un complément intéressant au modèle linéaire ou au modèle linéaire généralisé.

i. Quelques autres modèles

Concernant les méthodes de modélisation statistique, on ne saurait être exhaustif dans cette introduction. Parmi les méthodes récentes, faisant un usage intensif de l'ordinateur, citons, pour mémoire :

- ✓ **la régression PLS (Partial Least Squares),**
- ✓ **les méthodes d'agrégation, ou de combinaison, de modèles (bagging, boosting, random forests),**
- ✓ **les méthodes de régularisation**
- ✓ **et les SVM (Support Vector Machines).**

Dans ce document, nous n'aborderons qu'un petit nombre de modèles parmi ceux évoqués ci-dessus. En fait, tous les modèles qui seront abordés relèvent du modèle linéaire gaussien : le modèle de base.



2. PRELIMINAIRES A TOUTE MODELISATION STATISTIQUE

Quel que soit le modèle, ou le type de modèles, envisagé face à un jeu de données, quel que soit le problème qu'il s'agit de traiter, une modélisation statistique ne peut sérieusement s'envisager que sur des données "propres", c'est à dire pré-traitées, afin de les débarrasser, autant que faire se peut, de tout ce qui peut nuire à la modélisation : codes erronés, données manquantes, données aberrantes, variables inutiles, variables redondantes... C'est cet ensemble de pré-traitements que nous décrivons dans ce paragraphe. On notera que cette phase est parfois appelée **datamanagement**, autrement dit "gestion des données".

a. "Nettoyage" des données

Avant toute chose, il faut disposer d'un fichier informatique contenant les données dans un format exploitable (texte ou Excel, par exemple), les individus étant disposés en lignes et les variables en colonnes. Avec ce fichier, il faut essayer de repérer d'éventuels codes interdits ou aberrants : chaîne de caractères pour une variable numérique ; code "3" pour la variable sexe ; valeur 153 pour l'âge d'un groupe d'individus, etc. Une fois repérés, ces codes doivent être corrigés si possible, supprimés sinon. Dans cette phase, il faut également essayer de repérer des données manquantes en grande quantité, soit sur une colonne (une variable), soit sur une ligne (un individu). Si quelques données manquantes ne sont pas vraiment gênantes dans la plupart des traitements statistiques, il n'en va pas de même lorsque cela concerne un fort pourcentage des observations d'une variable ou d'un individu. Dans ce cas, il est préférable de supprimer la variable ou l'individu (dont la colonne, ou la ligne, serait, de toutes façons, inexploitable).

b. Analyse univariée

Cette phase, souvent fastidieuse, consiste à étudier chaque variable l'une après l'autre, afin d'en connaître les principales caractéristiques et d'en repérer, le cas échéant, certaines anomalies.

Pour les variables quantitatives, on pourra faire un histogramme ou un diagramme en boîte et déterminer des caractéristiques telles que le minimum, le maximum, la moyenne, l'écart-type, la médiane et les quartiles. Cela peut conduire à supprimer une variable (si elle présente très peu de variabilité), à la transformer (par exemple, en prenant son logarithme si elle est à valeurs positives et très dissymétrique), ou encore à repérer des valeurs très particulières (que l'on devra, éventuellement, corriger ou éliminer).

Pour les variables qualitatives, on pourra faire un diagramme en colonnes des modalités et déterminer les effectifs et les fréquences de ces dernières. Cela pourra encore conduire à supprimer une variable (si tous les individus, ou presque, présentent la même modalité), ou à en regrouper des modalités "proches" (si certains effectifs sont trop faibles).

Ces analyses univariées permettent également de prendre connaissance des données et de fournir certaines indications pour la phase ultérieure de modélisation. Toutefois, il faut noter que ces analyses peuvent être inenvisageables avec des données "fortement multidimensionnelles", c'est-à-dire comportant des centaines, voire des milliers, de variables ; on rencontre aujourd'hui de telles données dans certains contextes particuliers.

c. Analyses bivariées

Ces analyses ont pour but d'étudier d'éventuelles liaisons existant entre couples de variables. Il peut s'agir de deux variables explicatives, dont on soupçonne qu'elles sont fortement corrélées, dans le but d'éliminer l'une des deux. Il peut aussi s'agir d'étudier les liens entre la variable à expliquer et chaque variable explicative (de façon systématique), pour avoir une première idée des variables explicatives susceptibles de jouer un rôle important lors de la modélisation. Enfin, ces analyses peuvent aussi permettre de repérer des points aberrants (ou extrêmes) qui n'ont pas pu l'être avec les analyses univariées.

Rappelons que, pour étudier la liaison entre deux variables quantitatives, on dispose, comme graphique, du nuage de points (ou diagramme de dispersion) et, comme indicateur de liaison, du coefficient de corrélation linéaire. Dans le cas d'une variable quantitative et d'une variable qualitative, on dispose du diagramme en boîtes parallèles et du rapport de corrélation. Enfin, dans le cas de deux variables qualitatives, on utilise en général un diagramme en colonnes de profils (profils-lignes ou profils-colonnes selon ce que l'on souhaite mettre en évidence) et des indicateurs de liaison liés au khi-deux (coefficients de Tschuprow ou de Cramer).

d. Analyses multivariées quantitatives

Elles consistent à déterminer la matrice des corrélations entre toutes les variables quantitatives considérées, notamment la variable à expliquer, lorsque celle-ci est quantitative. Cela peut permettre encore de supprimer des variables très corrélées, par exemple afin d'éviter de faire une régression sur de telles variables, dont on sait que les résultats seraient très instables, voire sans aucune signification. Cela permet aussi de prendre connaissance de la structure de corrélation entre les variables considérées, ce qui est toujours utile dans le cadre d'une modélisation.

On peut également envisager, à ce niveau, de réaliser une analyse en composantes principales (A.C.P.) de toutes ces variables, afin de préciser davantage, de façon globale, leurs relations linéaires.

e. Analyses multivariées qualitatives

C'est le pendant des analyses ci-dessus, cette fois pour les variables qualitatives. On peut, tout d'abord, déterminer la matrice des coefficients de Tschuprow (ou celle des coefficients de Cramer) et l'analyser comme une matrice de corrélations. Toutefois, il est bien connu que, dans la pratique, ces coefficients sont systématiquement petits : pratiquement toujours inférieurs à 0.5 et le plus souvent compris entre 0.1 et 0.3. Leur interprétation est donc, en général, assez délicate. Ils permettent néanmoins de repérer les liaisons les plus importantes, même si elles sont de l'ordre de 0.3, 0.4 ou 0.5.


Il est d'autant plus important d'envisager, dans ces analyses préliminaires, de réaliser une analyse des correspondances multiples (A.C.M.) entre variables qualitatives. Celle-ci permettra, le cas échéant, de confirmer une liaison forte entre certains couples de variables et, si nécessaire, d'en éliminer quelques-unes. L'A.C.M. permet également de regrouper certaines modalités d'une même variable lorsque celles-ci apparaissent proches dans l'ensemble des résultats et, par suite, de simplifier les données. Enfin, le tableau de Burt, fourni avec les résultats de l'A.C.M., permet de repérer des occurrences très faibles pour certains croisements de modalités et d'envisager encore d'autres regroupements.

f. Bilan

Une fois réalisées toutes les étapes préliminaires décrites ci-dessus, on dispose de données “mises au propre”, simplifiées, et dont on commence à connaître certaines caractéristiques. On peut, à partir de ce moment-là, envisager leur modélisation.

Les modèles susceptibles d'être adaptés aux données considérées, parmi tous ceux décrits dans le paragraphe précédent, sont nécessairement limités à ce stade-là. Ils sont fonction de la nature des données ainsi que des questions posées par l'utilisateur, autrement dit de ses objectifs.

Insistons ici sur le fait que des données sont toujours recueillies (produites) par un utilisateur (biologiste, informaticien, gestionnaire...) dans un but bien précis. La modélisation statistique doit avoir pour objectif premier de répondre aux questions que s'est posé cet utilisateur lorsqu'il a décidé de recueillir les données. Une collaboration entre utilisateur et statisticien est donc, à ce niveau-là, absolument indispensable.



3. LES ETAPES DU PROCESSUS DE MODELISATION

1. Estimer les valeurs des coefficients ($\beta_0 ; \beta_1 ; \beta_2 ; \dots ; \beta_p$) à partir d'un échantillon de données (estimateur des moindres carrés ordinaires).
2. Évaluer la précision de ces estimations (biais, variance des estimateurs).
3. Mesurer le pouvoir explicatif du modèle dans sa globalité (tableau d'analyse de variance, coefficient de détermination).
4. Tester la réalité de la relation entre Y et les exogènes X_j (test de significativité globale de la régression).
5. Tester l'apport marginal de chaque variable explicative dans l'explication de Y (test de significativité de chaque coefficient).
6. Tester l'apport d'un groupe de variables explicatives dans l'explication de Y (test de significativité simultanée d'un groupe de coefficient).
7. Pour un nouvel individu i^* pour lequel on fournit la description ($x_{*1} ; \dots ; x_{*p}$), calculer la valeur prédite y^* et la fourchette de prédiction.
8. Interpréter les résultats en mettant en avant notamment l'impact des exogènes sur l'endogène (interprétation des coefficients, analyse structurelle).
9. Tester à postériori la validité du modèle c-à-d sa conformité avec les hypothèses de départ.
10. Si le modèle est satisfaisant, il peut servir à des fins explicatives ou prospectives sinon reprendre toutes les étapes précédentes avec une nouvelle spécification de modèle.

Variable à Expliquer	Variables explicatives	Nom de la technique de modélisation
1 quantitative	1 quantitative	Régression linéaire Simple
1 quantitative	n quantitatives	Régression linéaire Multiple
1 quantitative	1 qualitative	ANOVA à un facteur
1 quantitative	n qualitatives	ANOVA à n facteur
1 quantitative	n quantitatives + qualitatives	ANCOVA
n quantitative	n qualitatives	MANOVA à n facteur
n quantitative	n quantitatives + qualitatives	MANCOVA
1 qualitative	n quantitatives + qualitative	Analyse Discriminante Linéaire
1 qualitative	n quantitatives + qualitative	Régression Logistique
1 variable de comptage	n quantitatives + qualitative	Régression de poisson
1 variable censurée ou tronquée	n quantitatives + qualitative	Régression Tobit
1 variable de durée	n quantitatives + qualitative	Régression de durée

4. ESIMATION DES PARAMETRES DU MODELE

Après spécification on a le modèle suivant : $Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$

Le premier problème statistique à résoudre est le calcul des paramètres β_0 et β_1 , sachant les observations de Y et de X.

Il existe deux méthodes permettant le calcul de β_0 et β_1 : la méthode des moindres carrés ordinaires (MCO) et la méthode du maximum de vraisemblance. L'utilisation de ces deux méthodes conduit à des valeurs calculées de β_0 et β_1 qui possèdent des propriétés statistiques remarquables. Cela implique qu'un certain nombre d'hypothèses de base soient vérifiées avant l'utilisation de ces méthodes.

1.1 Les hypothèses de base du modèle de régression linéaire simple

Le modèle étant $Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$ il comporte deux parties :

- ✓ la partie déterministe ou systématique : $Y_t = f(X_t)$
- ✓ la partie aléatoire ou stochastique : $Y_t = f(\varepsilon_t)$

a. Hypothèses sur la partie déterministe ou systématique : Y_t et X_t

- ⇒ **H1.** Les variables X et Y sont observées sans erreur. Y est aléatoire par l'intermédiaire de ε_t , c'est-à-dire que la seule erreur possible sur Y provient des insuffisances de X à expliquer ses valeurs dans le modèle et X n'est pas aléatoire
- ⇒ **H2.** La variable Y doit être gaussienne.
- ⇒ **H3.** Le modèle est linéaire en ses paramètres tels que l'exprime l'équation.
- ⇒ **H4.** Le nombre d'observations n doit être supérieur au nombre des paramètres à estimer.

b. Hypothèses sur la partie aléatoire : ε_t

- ⇒ **H5.** $Cov(X, \varepsilon) = 0$ (**Hypothèse d'indépendance entre la partie déterministe et la partie aléatoire : hypothèse d'exogénéité des explicatives**) : X est une variable aléatoire contrôlée (indépendante de l'aléa) : Cette hypothèse signifie que l'erreur et les variables explicatives ont une influence séparée sur la variable endogène.)
- ⇒ **H6.** $E(\varepsilon_t) = 0$ (**Hypothèse de centralité des erreurs**) C'est-à-dire qu'en moyenne, l'influence de ε_t sur le modèle est nulle, ce qui revient à admettre que le modèle est correctement spécifié. Autrement dit les effets des facteurs autres que le prédicteur (régresseur ou la variable explicative) s'équilibrent.
- ⇒ **H7.** $V(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$ (**Hypothèse d'homoscédasticité des erreurs**) Les erreurs ε_t ont une variance constante et finie. Plus explicitement, il s'agit d'assumer que les variables explicatives omises dans le modèle influent toutes pratiquement de façon constante sur la variable expliquée.
- ⇒ **H8.** $Cov(\varepsilon_t, \varepsilon_s) = 0$ (**Hypothèse de non autocorrélation des erreurs**) Les erreurs ε_t de différentes périodes sont indépendantes les unes des autres.

Ces quatre hypothèses sont fondamentales pour l'application de la méthode des MCO. Pour utiliser la méthode du maximum de vraisemblance, on suppose en outre vérifiée l'hypothèse de normalité des aléas c'est-à-dire :

- ⇒ **H9.** $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ (**Hypothèse de normalité des erreurs**) Cette hypothèse est la clé de l'inférence statistique. Elle est donc nécessaire pour mener les tests.


Trois quantités sont donc inconnues dans ce modèle : β_0 ; β_1 et σ_ε^2 . L'objectif des méthodes d'estimation est de trouver des estimateurs de ces paramètres inconnus qui possèdent les propriétés requises par la théorie statistique (**estimateur non biaisé, convergent, à variance minimum et robuste**)

5. ESIMATEURS DES MCO : Moindres Carrés Ordinaires

La méthode des MCO consiste à minimiser la somme des carrés des écarts, écarts entre la valeur observée de la variable endogène (pour un point du nuage) et sa valeur calculée par le modèle. Graphiquement, il s'agit de la distance mesurée parallèlement à l'axe des ordonnées entre ces deux points.

De ce fait, l'écart entre l'observé et le calculé est le résidu, noté e_t .

On rappelle que $e_t = Y_t - \hat{Y}_t$



MCO :

$$\text{Min} \sum_{t=1}^n e_t^2$$

$$\text{Min} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2$$

$$\text{Min} \sum_{t=1}^n (Y_t - \hat{\beta}_0 - \hat{\beta}_1 X_t)^2$$

$$\text{Min} \phi(\hat{\beta}_0, \hat{\beta}_1)$$

Il s'agit de la minimisation d'une fonction ϕ à deux inconnues $\hat{\beta}_0$ et $\hat{\beta}_1$. La solution, si elle existe, est donnée par le système d'équations normales suivant :

$$\begin{cases} \frac{\partial \phi}{\partial \hat{\beta}_0} = 0 \\ \frac{\partial \phi}{\partial \hat{\beta}_1} = 0 \end{cases}$$

$$\frac{\partial \phi}{\partial \hat{\beta}_0} = -2 \sum (Y_t - \hat{\beta}_0 - \hat{\beta}_1 X_t) = 0 \Leftrightarrow n\bar{Y} - n\hat{\beta}_0 - \hat{\beta}_1 n\bar{X} = 0$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

La droite passe par le centre de gravité $G(\bar{X}, \bar{Y})$ du nuage de régression.

$$\frac{\partial \phi}{\partial \hat{\beta}_1} = -2 \sum (Y_t - \hat{\beta}_0 - \hat{\beta}_1 X_t) X_t = 0$$

$$\Leftrightarrow \sum (Y_t - (\bar{Y} - \hat{\beta}_1 \bar{X}) - \hat{\beta}_1 X_t) X_t = 0$$

$$\Leftrightarrow \sum (Y_t X_t - \bar{Y} X_t + \hat{\beta}_1 \bar{X} X_t - \hat{\beta}_1 X_t^2) = 0$$

$$\Leftrightarrow \sum Y_t X_t - n\bar{X}\bar{Y} + \hat{\beta}_1 n\bar{X}^2 - \hat{\beta}_1 \sum X_t^2 = 0$$

$$\Leftrightarrow \sum Y_t X_t - n\bar{X}\bar{Y} - \hat{\beta}_1 (\sum X_t^2 - n\bar{X}^2) = 0$$

$$\Leftrightarrow \hat{\beta}_1 = \frac{\sum Y_t X_t - n\bar{X}\bar{Y}}{\sum X_t^2 - n\bar{X}^2}$$

Un développement mathématique simple permet d'exprimer $\hat{\beta}_1$ par le produit de la covariance empirique entre X et Y et de la variance empirique de X.

$$\hat{\beta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum (Y_t - \bar{Y})(X_t - \bar{X})}{\sum (X_t - \bar{X})^2}$$

Il faut vérifier que $\hat{\beta}_0$ et $\hat{\beta}_1$ minimisent bien la somme des $\sum_{t=1}^n e_t^2$

Pour cela, on calcule les dérivées secondes.

$$\begin{cases} \frac{\partial^2 \phi}{\partial \beta_0^2} = 2 > 0 \\ \frac{\partial^2 \phi}{\partial \beta_1^2} = 2 \sum X_t^2 > 0 \end{cases}$$

Les dérivées partielles secondes sont positives. La solution trouvée par les dérivées partielles premières $(\hat{\beta}_0, \hat{\beta}_1)$ est un minimum.

Estimateur de la variance de l'erreur σ_ε^2

Détermination d'un estimateur sans biais de σ_ε^2 qui est un paramètre inconnu pour l'utilisation des MCO.

On montre que l'estimateur sans biais de σ_ε^2 est :

$$\hat{\sigma}_\varepsilon^2 = \frac{\sum e_t^2}{n-2}$$

Avec $e_t = Y_t - \hat{Y}_t$

L'étape suivante est maintenant de vérifier si les estimateurs $\hat{\beta}_0$; $\hat{\beta}_1$ et $\hat{\sigma}_\varepsilon^2$ des paramètres du modèle théorique β_0 ; β_1 et σ_ε^2 sont :

- ⇒ Sans biais
- ⇒ Convergents
- ⇒ A variance minimum

En d'autres termes, si ces estimateurs sont BLUE [Best Linear Unbiased Estimator] c'est-à-dire qu'ils sont les meilleurs estimateurs linéaires, non biaisés et à variance minimale.

1.2 Les propriétés des estimateurs des moindres carrés ordinaires

On montre que sous les hypothèses du modèle linéaire générale simple spécifiées en début de chapitre, les estimateurs des MCO ont les caractéristiques ci-dessous :

- a. Les estimateurs des MCO sont des fonctions linéaires des Y_t de Y.
- b. $\hat{\beta}_0$ et $\hat{\beta}_1$ sont des estimateurs (linéaires) sans biais de β_0 et β_1
- c. $\hat{\beta}_0$ et $\hat{\beta}_1$ sont des estimateurs convergents.
- d. $\hat{\beta}_0$ et $\hat{\beta}_1$ sont des estimateurs à variance minimale de β_0 et β_1

$$\text{Var}(\hat{\beta}_0) = \hat{\sigma}_\varepsilon^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum (X_t - \bar{X})^2} \right)$$

$$\text{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}_\varepsilon^2}{\sum (X_t - \bar{X})^2}$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\hat{\sigma}_\varepsilon^2 \sum \frac{\bar{X}}{\sum (X_t - \bar{X})^2}$$

Remarque :

Il est important de noter que toutes les propriétés énoncées dans cette section sont valables quelle que soit la loi des résidus ε_i . Quand on rajoute une hypothèse sur cette loi, on peut donner des précisions sur la loi des estimateurs, leur qualité, construire des intervalles de confiance et des tests d'hypothèses sur les paramètres du modèle. C'est ce qu'on fera dans la section suivante en supposant les résidus de loi normale.

Chapitre 1

REGRESSION LINEAIRE

- Modèle linéaire Simple
- Modèle linéaire multiple
- Analyse de la variance à 1 facteur
- Analyse de la variance à deux facteurs
- Analyse de la covariance

DEFINITION DE LA METHODE

La régression linéaire simple est une méthode statistique permettant de modéliser la relation linéaire entre deux variables quantitatives dans un objectif **explicatif et / ou prévisionnel**. Nous disposons d'une variable explicative (notée X) et une variable à expliquer (noté Y) liées par le modèle suivant :

$$Y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

LES HYPOTHESES DU MODELE

Le modèle étant $Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$ il comporte deux parties :

- ❖ la partie déterministe ou systématique : $Y_t = f(X_t)$
- ❖ la partie aléatoire ou stochastique : $Y_t = f(\varepsilon_t)$

Hypothèses sur la partie déterministe ou systématique : Y_t et X_t

- **H1.** Les variables X et Y sont observées sans erreur. Y est aléatoire par l'intermédiaire de ε_t , c'est-à-dire que la seule erreur possible sur Y provient des insuffisances de X à expliquer ses valeurs dans le modèle et X n'est pas aléatoire
- **H2.** Le modèle est linéaire en ses paramètres tels que l'exprime l'équation.
- **H3.** Y suit une loi normale

Hypothèses sur la partie aléatoire : ε_t

- **H3.** $Cov(X, \varepsilon) = 0$ (Hypothèse d'indépendance entre la partie déterministe et la partie aléatoire : hypothèse d'exogénéité des explicatives) : X est une variable aléatoire contrôlée (indépendante de l'aléa) : Cette hypothèse signifie que l'erreur et les variables explicatives ont une influence séparée sur la variable endogène.)
- **H4.** $E(\varepsilon_t) = 0$ (Hypothèse de centralité des erreurs) C'est-à-dire qu'en moyenne, l'influence de ε_t sur le modèle est nulle, ce qui revient à admettre que le modèle est correctement spécifié. Autrement dit les effets des facteurs autres que le prédicteur (régresseur ou la variable explicative) s'équilibrent.
- **H5.** $V(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$ (Hypothèse d'homoscédasticité des erreurs) Les erreurs ε_t ont une variance constante et finie. Plus explicitement, il s'agit d'assumer que les variables explicatives omises dans le modèle influent toutes pratiquement de façon constante sur la variable expliquée.
- **H6.** $Cov(\varepsilon_t, \varepsilon_s) = 0$ (Hypothèse de non autocorrélation des erreurs) Les erreurs ε_t de différentes périodes sont indépendantes les unes des autres. Ces quatre hypothèses sont fondamentales pour l'application de la méthode des MCO. Pour utiliser la méthode du maximum de vraisemblance, on suppose en outre vérifiée l'hypothèse de normalité des aléas c'est-à-dire :
- **H7.** $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ (Hypothèse de normalité des erreurs) Cette hypothèse est la clé de l'inférence statistique. Elle est donc nécessaire pour mener les tests.

PRESENTATION DE LA STRUCTURE DES DONNEES (DATAFRAME OU AUTRE STRUCTURE DE DONNEE)

Le tableau ci-dessous représente l'évolution du revenu disponible brut et de la consommation des ménages en euros pour un pays donné sur la période 1992-2001. [Pour les calculs, prendre 4 chiffres après la virgule].

Année	Revenu	Consommation
1992	8000	7389.99
1993	9000	8169.65
1994	9500	8831.71
1995	9500	8652.84
1996	9800	8788.08
1997	11000	9616.21
1998	12000	10593.45
1999	13000	11186.11
2000	15000	12758.09
2001	16000	13869.62

On cherche à expliquer la consommation des ménages (C) par le revenu (R), soit : $C_t = \alpha + \beta R_t + u_t$

MISE EN ŒUVRE DE LA METHODE SOUS R

ETAPES

- # 1ere étape : Importer les données
- # 2eme étape : Représenter le nuage de points
- # 3eme étape : Estimer les paramètres
- # 4eme étape : Tracer la droite de régression
- # 5eme étape : Analyser les résidus
- # 6eme étape : Tester la validité du modèle
- # 7eme étape : Prévoir une nouvelle valeur

INSSEDS

```
# 1ere étape : Importer les données
```

```
# +-----+##
```

```
rm(list=objects())  
graphics.off()
```

```
setwd("C:/Users/ASUS/Desktop/jeudonnee")  
mods<-read.table("modlinsimple.csv",header=TRUE, sep=";",  
dec="," ,check.names=FALSE)  
mods
```

```
  consommation  revenu  
1      7389.99    8000  
2      8169.65    9000  
3      8831.71    9500  
4      8652.84    9500  
5      8788.08    9800  
6      9616.21   11000  
7     10593.50   12000  
8     11186.10   13000  
9     12758.10   15000  
10    13869.60   16000
```

```
summary(mods)  
  consommation      revenu  
Min.   : 7390    Min.   : 8000  
1st Qu.: 8687    1st Qu.: 9500  
Median : 9224    Median :10400  
Mean   : 9986    Mean   :11280  
3rd Qu.:11038    3rd Qu.:12750  
Max.   :13870    Max.   :16000
```

```
names(mods)  
[1] "consommation" "revenu"
```


```
dim(mods)  
[1] 10  2
```

```
attributes(mods)  
$names  
[1] "consommation" "revenu"
```

```
$class  
[1] "data.frame"
```

```
$row.names  
[1] 1  2  3  4  5  6  7  8  9 10
```

```
# 2eme étape : Représenter le nuage de points
# +-----+
plot(consommation~revenu,data=mods)
```



```
# 3eme étape : Estimer les paramètres
```

```
# Faire la régression
regS <- lm(consommation ~ revenu, mods)
regS$coefficients
(Intercept)      revenu
1176.0993859      0.7809821

# Voir l'intervalle de confiance des coefficients estimés
confint(regS)
                2.5 %      97.5 %
(Intercept) 697.8570073 1654.3417644
revenu      0.7396149   0.8223494

# Voir l'ensemble des fonctions associées à lm
attributes(regS)
$names
 [1] "coefficients" "residuals"   "effects"
 [4] "rank"         "fitted.values" "assign"
 [7] "qr"           "df.residual"  "xlevels"
[10] "call"         "terms"        "model"
$class
[1] "lm"

# Voir le résumé des résultats (bien comprendre les résultats ici)
summary(regS)
Call:
lm(formula = consommation ~ revenu, data = mods)
Residuals:
    Min       1Q   Median       3Q      Max
-150.69 -109.96  -34.63   54.46  236.28
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.176e+03  2.074e+02   5.671  0.00047 ***
revenu       7.810e-01  1.794e-02  43.536 8.55e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 143.7 on 8 degrees of freedom
Multiple R-squared:  0.9958,    Adjusted R-squared:  0.9953
F-statistic: 1895 on 1 and 8 DF, p-value: 8.548e-11
```

REMARQUES :

1) Il est d'usage de commencer par regarder si le modèle est significativement différent de zéro dans les sorties de **summary()** grâce à la p-value du test de Fisher. Si cette p-value est supérieure à **0,05** «**le modèle ne vaut rien**». Si le modèle est significativement différent de zéro, on peut s'intéresser directement au coefficient de détermination en régression linéaire simple.

comparer les résultats du résumé avec ceux-ci
`anova(regS)`

2) La valeur de R^2 est donnée, ainsi que le R_a^2 ajustée. La valeur du R^2 est élevée ($R^2 = 0.9958$), ce qui corrobore l'intuition de la relation linéaire entre les deux variables. En d'autres termes, **99,58%** de la variabilité de la consommation est expliquée par le revenu.

3) Les valeurs estimées par le modèle :

– Soit le modèle initial : $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

– Après estimation on obtient : $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$

- β_0 ici l'intercept (ou la constante) est estimé à **1.176e+03** avec un P-value **< 0.05**, ce qui veut dire la constante est significativement différent de zéro et qu'il doit apparaître dans le modèle. (L'intercept β_0 représente la valeur de l'espérance mathématique $E(Y_i)$ (moyenne de la variable dépendante Y_i) lorsque la valeur de la variable explicative est égale à **0**, c-a-d la **valeur moyenne de la consommation quand le revenu est nul est égale à 1.176e+03 euro**)


- β_1 ici la pente (coefficient) estimée à **7.810e-01** avec un P-value **< 0.05**, ce qui veut dire la constante est significativement différent de zéro. Cela indique qu'il y a une liaison significative entre le revenu et la consommation. (Le coefficient β_1 , associé à la variable explicative x_i , représente la **variation de $E(Y_i)$** (espérance de la variable dépendante Y_i) lorsque x_i augmente d'une unité, donc quand le revenu augmente d'1 euro la consommation augmente de **7.810e-01 euro**.)

- σ_ε^2 ici l'écart-type résiduel est estimé à **143.7** ainsi que le nombre de degré de liberté $(n-2) = 8$

Pour faire une régression sans constante
`reg.ss.cte<-lm(consommation~revenu-1,mods)`
`reg.ss.cte`

```
# 4eme étape : Tracer la droite de régression
# +-----+##
```

```
# Nous pouvons simplement appliquer la fonction abline
abline(regS)
```




```
# 5eme étape : Analyser les résidus visuellement
# +-----+##
```

1) Les résidus studentisés

Les résidus sont obtenus par la fonction **residuals**, cependant les résidus obtenus ne sont pas de même variance (hétéroscédastiques). Nous utilisons donc des résidus studentisés ; qui eux sont de même variance.

```
residus<-residuals(regS)
residus
res.simple<-rstudent(regS)
plot(res.simple,pch=15,cex=.5,ylab="Residus",ylim=c(-3,3))
abline(h=c(-2,0,2),lty=c(2,1,2))
```




En théorie 95% des résidus studentisés se trouvent dans l'intervalle $[-2;2]$. Ici on a 80% des résidus qui se trouvent dans cet intervalle (8 points sur les 10 points). Ce qui est acceptable.

```
res_std<-rstudent(regS)
sum(as.numeric(abs(res_std)<=2))/nrow(mods)*100
```

[1] 80

2) Voir certains graphiques de l'analyse

`par(mfrow=c(2,2), mar=c(2,2,2,2))``plot(regS)`**Le graphique 1 (Residuals vs Fitted)**

Permet de voir s'il y a un problème d'hétéroscédasticité (variance non constante). L'homoscédasticité et la linéarité du modèle sont évalués par un graphique des résidus studentisés ou non : $(\hat{y}_i e_i)$ qui doit se disperser "normalement" de part et d'autre de l'axe $y = 0$: symétriquement et sans forme particulière. Des formes d'"entonnoir", ou de "diabolo" du nuage font suspecter une hétéroscédasticité des résidus, celle d'une "banane" indique une possible relation non linéaire entre Y et X.

Le graphique 2 (QQ-plot)

Permet de vérifier l'hypothèse de normalité des résidus : si les points sont à peu près alignés en se confondant avec la première bissectrice des axes, on peut dire que les résidus suivent une loi normale.

Le graphique 4 (Cook's D)

Permet de repérer les points « influents », c'est à dire ceux pour qui la régression linéaire est mal (ou pas) adaptée, parce qu'ils se situent trop loin de la droite de régression. Ces points sont repérés par de grandes valeurs du D de Cook (les points 3 et 10).

```
# 6eme étape : Faire les tests de validité du modèle
# +-----+
#
```

LES DONNEES

```
residus<-residuals(regS)
res.normalise<-rstudent(regS)
mods$revenu
mods$consommation
val.estimees<-fitted.values(regS)
```

1) test si de $Cov(X, \varepsilon) = 0$

$H_0 : r_{xy} = 0$; la partie déterministe du modèle n'est pas liée à la partie aléatoire du modèle

$H_1 : r_{xy} \neq 0$; la partie déterministe du modèle est liée à la partie aléatoire du modèle

```
cor.test(mods$revenu, residus^2, method="pearson")
      Pearson's product-moment correlation
```

```
data:  mods$revenu and residus^2
t = 1.117, df = 8, p-value = 0.2964
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.3412426  0.8096787
sample estimates:
      cor
0.3673001
```

Conclusion : la p-value > 0.05 donc on ne peut rejeter H_0 , le coefficient de corrélation n'est pas significativement différente de zéro. Donc $Cov(X, \varepsilon) = 0$.

REMARQUE :

Problème :

Lorsque cette hypothèse n'est pas respectée, l'estimateur des moindres carrés ordinaires est biaisé et n'est pas convergent (le biais ne tend donc pas à disparaître si la taille de l'échantillon est grande). Il produirait donc une erreur systématique des valeurs estimées.

Solution :

La méthode des variables instrumentales est plus efficace que les MCO pour estimer les paramètres du modèle en cas d'endogénéité des explicatives.

2) test de linéarité du modèle

Test de Rainbow :

Pour conclure à la non-linéarité du modèle de régression, on préconise le test de Rainbow : si p-valeur < 0.05, on rejette la linéarité du modèle et on admet qu'un modèle de régression non-linéaire est plus adapté aux données.

H_0 : le modèle est linéaire

H_1 : le modèle n'est pas linéaire

```
library(lmtest)
raintest(regM)
```

```
      Rainbow test
data:  regM
Rain = 1.0108, df1 = 225, df2 = 219, p-value = 0.4683
```

Conclusion : la p-value > 0.05 donc on ne peut rejeter H_0 , le modèle est linéaire

3) Test de $E(\varepsilon_t) = 0$: vérifier qu'en moyenne le modèle est bien spécifié

```
mean(residus)
```

```
[1] -5.681566e-15 ≈ 0
```

4) $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ normalité des erreurs**TEST DE SHAPIRO WILK**

```
#  $H_0$  : La distribution suit la loi normale
```

```
#  $H_1$  : La distribution ne suit pas la loi normale
```

```
shapiro.test(residus)
```

```
Shapiro-Wilk normality test
```

```
data: residus
```

```
W = 0.90008, p-value = 0.2195
```

```
# Conclusion : p-value > 0.05, on ne peut rejeter  $H_0$  : Donc la distribution suit une loi normale
```

TEST DE JARQUE BERA

```
library(tseries)
```

```
regS<-lm(consumation~revenu,mods)
```

```
residus<-residuals(regS)
```

```
jarque.bera.test(residus)
```

```
Jarque Bera Test
```

```
data: residus
```

```
X-squared = 0.85714, df = 2, p-value = 0.6514
```

```
# Conclusion : p-value > 0.05, on ne peut rejeter  $H_0$  : Donc la distribution suit une loi normale
```

REMARQUE :

Problème : Sa violation ne touche pas le caractère non biaisé des paramètres mais rend l'inférence, dans le modèle linéaire, impossible car les distributions des estimateurs ne sont plus connues.


Solution :

- ✓ Le meilleur remède à la non-normalité des résidus est d'agrandir la taille de l'échantillon.
- ✓ La transformation de Box – Cox, sur les variables non normales intervenant dans le modèle, est souvent aussi indiquée.


INSSEDS

5) $V(\varepsilon_t) = E(\varepsilon_t^2) = \sigma_\varepsilon^2$ (Hypothèse d'homoscédasticité des erreurs)

Il y a homoscédasticité quand les erreurs sont de variance constante. Le graphe ci-dessous montre que la variance des résidus augmente avec les valeurs d'une des exogènes, c'est un cas d'hétéroscédasticité.



```
residus<-residuals(regS)
residus
res.simple<-rstudent(regS)
plot(res.simple,pch=15,cex=.5,ylab="Residus",ylim=c(-3,3))
abline(h=c(-2,0,2),lty=c(2,1,2))
```



TEST DE BREUSCH-PAGAN

H_0 : il y a homoscédasticité

H_1 : il n'y a pas hétéroscédasticité

```
install.packages("lmtest")
```

```
library(lmtest)
```

```
bptest(regS)
```

studentized Breusch-Pagan test

```
data: regS
```

```
BP = 1.3491, df = 1, p-value = 0.2454
```

Conclusion : p-value > 0.05, on ne peut rejeter H_0 : Donc il y a homoscédasticité

1

TEST DE WHITE H_0 : il y a homoscedasticité H_1 : il y a hétéroscedasticité

```
regS<-lm(consommation~revenu,mods)
install.packages("het.test")
install.packages("var")
library(het.test)
library(vars)
mod<-VAR(mods)
whites.htest(mod)
```

White's Test for Heteroskedasticity:

```
=====
No Cross Terms
H0: Homoskedasticity
H1: Heteroskedasticity
Test Statistic:
9.3441
Degrees of Freedom:
12
P-value:
0.6733
```

Conclusion : p-value > 0.05, on ne peut rejeter H_0 : Donc il y a homoscedasticité

REMARQUE :**Problème :**

La conséquence directe de cette violation est que les estimateurs des MCO, bien que encore non biaisés, ne sont plus efficaces, puisque n'ayant plus une variance minimale. Et par conséquent les t de Student et F de Fisher ne sont plus utilisables à des fins d'inférence.

Solution :

Si l'hypothèse d'homoscedasticité n'est pas vérifiée, on peut effectuer une transformation pour stabiliser la variance. Les deux transformations les plus courantes sont :

- Y en $\log Y$ si σ est proportionnel $E(Y)$
- Y en $\sqrt{Y}$ si σ^2 est proportionnel $E(Y)$

A chaque transformation, faire le test graphique pour voir si le problème est résolu par la transformation des variables. On verra cela en détail en régression multiple.


```
consommation2<-sqrt(abs(consommation))
reg2=lm(consommation2~revenu)
```

ou


```
consommation3<-log(abs(consommation))
reg3=lm(consommation3~revenu)
```

6) Test d'autocorrélation des erreurs $Cov(\varepsilon_t, \varepsilon_s) = 0$

On a une autocorrélation des erreurs lorsque les erreurs sont liées par un processus de reproduction. On peut distinguer l'autocorrélation positive de l'autocorrélation négative.




```
res.simple<-rstudent(regS)
plot(res.simple,pch=15,cex=.5,ylab="Residus",ylim=c(-3,3),type="b")
abline(h=c(-2,0,2),lty=c(2,1,2))
```



```
acf(residus,plot = FALSE)
Autocorrelations of series 'residus', by lag
```

Lag	0	1	2	3	4	5	6	7	8	9
Autocorrelation	1.000	-0.063	-0.262	0.009	-0.091	-0.279	-0.100	0.341	-0.015	-0.041

```
acf(residus,lag.max=20,plot = TRUE)
acf(residus,plot = TRUE)
```



Conclusion : La droite horizontale pointillée sur le graphique issu de la fonction "acf" nous indique le seuil critique au-delà duquel l'autocorrélation est considérée significative. En effet, sous hypothèse d'indépendance, la corrélation croisée de deux séries X et Y (de même taille n, et de même moyenne et écart-type) sera dans 95% des cas comprise dans l'intervalle

TEST DE DURBAN - WATSON**conditions**

- Pour utiliser ce test, le modèle doit comporter impérativement un terme constant
- La variable à expliquer ne doit pas figurer parmi les variables explicatives

$H_0 : \rho_1 = 0$ il n'y a pas d'autocorrélation d'ordre 1

$H_1 : \rho_1 \neq 0$ il y a une autocorrélation d'ordre 1

```
install.packages("lmtest")
```

```
library(lmtest)
```

```
dwtest(regS)
```

Durbin-Watson test

```
data: regS
```

```
DW = 1.8818, p-value = 0.2704
```

```
alternative hypothesis: true autocorrelation is greater than 0
```

Conclusion : La p-value > 0.05 donc on ne peut rejeter H_0 . Il n'y a DONC pas d'autocorrélation d'ordre 1

TEST DE BREUSCH-GODFREY

Il permet de tester une autocorrélation d'un ordre supérieur à 1, et il reste valide en présence de la variable à expliquer retardée parmi les variables explicatives

H_0 : il n'y a pas d'autocorrélation

H_1 : il a autocorrélation

```
library(lmtest)
```

```
bgtest(regS)
```

Breusch-Godfrey test for serial correlation of order up to 1

```
data: regS
```

```
LM test = 0.076629, df = 1, p-value = 0.7819
```

Conclusion : La p-value > 0.05 donc on ne peut rejeter H_0 . Il n'y a DONC pas d'autocorrélation d'ordre 1

REMARQUE :**Problème :**

Il y a autocorrélation des erreurs lorsque l'hypothèse $Cov(\varepsilon_t, \varepsilon_s) = 0$ est violée. La conséquence directe est que les estimateurs des MCO, bien qu'ils gardent encore leur caractère non biaisé, ne sont plus efficaces, puisque n'ayant plus une variance minimale.

Il faut noter aussi que l'autocorrélation des erreurs est un phénomène que l'on ne retrouve qu'en travaillant sur séries temporelles. En principe, le problème ne se pose pas sur cross sections, sauf le cas rare de corrélation spatiale des résidus,

Solution :

Lorsque le test conclut à l'évidence d'une autocorrélation, la correction se fait en appliquant la méthode des Moindres Carrés Généralisés [MCG ou GLS pour le sigle anglais] de Gauss-Aitken, qui consiste simplement à l'application des MCO sur les données transformées.

```
library(nlme)
```

```
reg2<-gls (consommation~revenu,data=mods)
```


```
summary (reg2)
```

Test de Chow : stabilité ou rupture de structure

Le test de Chow est un test statistique et économétrique afin de déterminer si les coefficients de deux séries linéaires sont égaux. Les coefficients sont établis par régression linéaire.

Il est surtout utilisé dans le cadre de séries temporelles pour savoir s'il y a une cassure significative par une certaine date qui séparerait les données en deux blocs ; il permet également d'évaluer l'impact des variables indépendantes sur les deux groupes ainsi construits. Ce test s'appuie sur la loi de Fisher.

Cassure temporelle dans un modèle



Il y a une cassure dans le modèle en $x = 1,7$, il faut donc effectuer une régression sur l'intervalle $[0 ; 1,7]$ et l'intervalle $[1,7 ; 4]$. Cela donnera une meilleure estimation qu'une régression globale et compactée en un modèle


```
# H0 : il n'y a pas de rupture de structure
# H1 : il a rupture de structure
install.packages("strucchange")
library(strucchange)
sctest(y ~ x)
```

Exemple

```
x=seq(1,5,length=100)
y=numeric(100)
y[1:50]=2*x[1:50]
y[51:100]=rep(2*x[51],50)
z=rnorm(100,0,.15)
y=y+z
plot(x,y)
```

y a-t-il un changement ou rupture de structure au point 3 ?

```
library(strucchange)
sctest(y ~ x, type = "Chow", point = 3)
Chow test
data: y ~ x
F = 4.1733, p-value = 0.01828
```



Conclusion : La p-value < 0.05 donc on rejette H_0 . Il y a un changement de structure, il faut donc faire 2 régressions au lieu d'une seule

H_0 : il n'y a pas de rupture de structure

H_1 : il y a rupture de structure

```
library(strucchange)
```


```
sctest(mods$consommation~mods$revenu,type = "Chow")
```

Chow test

```
data: mods$consommation ~ mods$revenu
```

```
F = 1.137, p-value = 0.3813
```

Conclusion : La p-value > 0.05 donc on ne peut rejeter H_0 . Il n'y a pas un changement de structure, il faut donc faire 1 régression au lieu de deux



```
# 6eme étape : Prévoir une nouvelle valeur
# +-----+

```

Ayant une nouvelle observation **xnew**, il suffit d'utiliser les estimations pour prévoir la valeur de Y correspondante. Cependant, la valeur prédite est de peu d'intérêt sans l'intervalle de confiance associée.

Exemple :

Nous disposons d'une nouvelle valeur du revenu (R11=20000 euros)

```
xnew<-20000
xnew<-as.data.frame(xnew)
colnames(xnew)<-"revenu"
predict(regS,xnew,interval="pred")
      fit      lwr      upr
1 16795.74 16294.86 17296.63

```

REMARQUES :

Il faut noter que l'argument **xnew** de la fonction **predict** doit être un data-frame avec les mêmes noms de la variable explicative (ici : revenu).


1) Représentation graphique de l'intervalle de confiance de valeurs lissées

Nous calculons ces intervalles pour l'ensemble de points ayant servi à dessiner la droite de régression.

```
regS<-lm(consommation~revenu,mods)
grillex<-seq(min(mods$revenu),max(mods$revenu),length=10)
grillex.df<-data.frame(grillex)
dimnames(grillex.df)[[2]]<- "revenu"
ICdte<-predict(regS,new=grillex.df,interval="conf",level=0.95)
plot(consommation~revenu-1,mods)
matlines(grillex,ICdte)
legend("topleft",lty=2:3,c("conf","prev"))

```


INSSEDS



2) Représentation graphique de l'intervalle de confiance de valeurs prédites

Nous calculons ces intervalles pour l'ensemble de points ayant servi à dessiner la droite de régression.

```
regS<-lm(consommation~revenu,mods)
grillex<-seq(min(mods$revenu),max(mods$revenu),length=10)
grillex.df<-data.frame(grillex)
dimnames(grillex.df)[[2]]<- "revenu"
ICprev<-predict(regS,new=grillex.df,interval="pred",level=0.95)
plot(consommation~revenu-1,mods)
matlines(grillex,ICprev)
legend("topleft",lty=2:3,c("conf","prev"))
```



3) Représentation graphique de l'intervalle de confiance de valeurs lissées et de valeurs prédites


Nous calculons ces intervalles pour l'ensemble de points ayant servi à dessiner la droite de régression.

```
grillex<-seq(min(mods$revenu),max(mods$revenu),length=10)
grillex.df<-data.frame(grillex)
```

```

dimnames(grillex.df)[[2]]<- "revenu"
ICdte<-predict(regS,new=grillex.df,interval="conf",level=0.95)
ICprev<-predict(regS,new=grillex.df,interval="pred",level=0.95)
plot(consumation~revenu-1,mods)
matlines(grillex,cbind(ICdte,ICprev[,-1]))
legend("topleft",lty=2:3,c("conf","prev"))

```



```

# Cas de régression linéaire simple avec une variable explication binaire
# +-----+

```

```

setwd("C:/Users/ASUS/Desktop/jeudonnee")
smp<-read.table("smp2.csv",header=TRUE,sep=";",check.names=FALSE)
str(smp)
summary(smp)

```

Expliquer la durée de l'entretien du détenu en fonction de la variable séparation (détenu séparé de sa famille dans son enfance, oui ou non) :

- smp\$separation : détenu séparé de sa famille dans son enfance, oui ou non
- smp\$dur.interv : durée de l'entretien avec le détenu

```
mod<-lm(smp$dur.interv~smp$separation)
```

```
mod$coefficients
```

```

(Intercept) smp$separation
61.7399527   0.5489362

```

```
# Voir l'intervalle de confiance des coefficients estimés
```

```

confint(mod)

                2.5 %      97.5 %
(Intercept)    59.858982 63.620923
smp$separation -2.330151  3.428023

```

```
summary(mod)
```

```

Call:
lm(formula = smp$dur.interv ~ smp$separation)

```

```
Residuals:
```

```

    Min       1Q   Median       3Q      Max
-61.74 -13.90  -1.74   12.71   58.26

```

```
Coefficients:
```

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)    61.7400     0.9581  64.439  <2e-16 ***
smp$separation  0.5489     1.4665   0.374   0.708
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 19.71 on 736 degrees of freedom
(61 observations deleted due to missingness)
Multiple R-squared:  0.0001903, Adjusted R-squared:  -0.001168
F-statistic: 0.1401 on 1 and 736 DF,  p-value: 0.7083

```

INTERPRETATION

Le test du coefficient de la variable séparation n'est pas significatif, on ne peut donc l'interpréter.

S'il était significatif, on dirait que par rapport à un détenu qui n'a pas été séparé de sa famille pendant son enfance, celui qui a été séparé a une durée d'entretien de 0.54 minute de plus.

