

Plan complet d'un projet d'analyse de données

De la compréhension du besoin métier au monitoring
Pipeline en 13 étapes : EDA, Machine Learning, déploiement

Sommaire

1. Compréhension du problème métier
 2. Collecte et compréhension des données
 3. Préparation des données
 4. Analyse descriptive (EDA)
 5. Analyse multivariée
 6. Feature Engineering
 7. Sélection des variables
 8. Modélisation (Machine Learning)
 9. Évaluation du modèle
 10. Interprétation du modèle
 11. Visualisation et Reporting
 12. Déploiement
 13. Monitoring et Maintenance
- Résumé du pipeline complet

*Pour une formation **Data Analyst**, les étapes 1 à 11 sont généralement suffisantes. Pour une formation **Data Scientist / Machine Learning Engineer**, les étapes 12 et 13 deviennent indispensables. Dans un projet d'agriculture intelligente basé sur l'IoT, les 13 étapes sont nécessaires pour aller jusqu'à un système opérationnel de recommandation des cultures et des intrants.*

01

Compréhension du problème métier (Business Understanding)

Avant même de charger les données, il est indispensable de répondre à plusieurs questions structurantes :

- Quel est le problème à résoudre ?
- Quels sont les objectifs du projet ?
- Quels indicateurs de performance (KPI) faut-il suivre ?
- Quelle valeur métier attend-on du projet ?

Exemple — Agriculture intelligente

- Prévoir le rendement d'une culture
- Détecter les carences du sol
- Recommander les meilleurs intrants

Cette étape conditionne toutes les suivantes : un objectif mal défini conduit généralement à une collecte de données inadaptée et à un modèle inutilisable en production.

02 Collecte et compréhension des données

Sources des données

- Fichiers CSV / Excel
- Bases de données (SQL, NoSQL)
- APIs
- Capteurs IoT
- Web Scraping

Compréhension des variables — Dictionnaire des données

Avant toute analyse, il est recommandé de documenter chaque variable du jeu de données dans un dictionnaire des données :

Variable	Description	Type
pH	Acidité du sol	Quantitative
Culture	Type de culture	Qualitative
Humidité	Humidité du sol	Quantitative

03 Préparation des données

Importation des librairies

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Chargement des données

```
df = pd.read_csv("sol.csv")
```

Nettoyage

Valeurs manquantes

```
df.isnull().sum()
```

Doublons

```
df.duplicated().sum()
```

Valeurs aberrantes

- IQR (écart interquartile)
- Z-score
- Isolation Forest

04 Analyse Descriptive (EDA)

A. Analyse Univariée

Variables quantitatives

Mesures de tendance centrale

- Moyenne
- Médiane
- Mode

Mesures de dispersion

- Variance
- Écart-type
- Étendue
- IQR

Visualisations

- Histogramme
- Boxplot
- Density Plot

Variables qualitatives

- Effectifs
- Fréquences
- Diagrammes en barres
- Camemberts

B. Analyse Bivariée

Quanti - Quanti

- Nuage de points
- Corrélation de Pearson
- Corrélation de Spearman

Quali - Quanti

- Boxplots
- Violin Plots
- ANOVA

Quali - Quali

- Tableau de contingence
- Test du χ^2
- Diagrammes empilés

05 Analyse Multivariée (souvent oubliée)

Elle étudie simultanément plusieurs variables afin de révéler des structures et des relations qui ne sont pas visibles dans les analyses univariée ou bivariée.

Matrice de corrélation

```
sns.heatmap(df.corr(), annot=True)
```

ACP — Analyse en Composantes Principales

Technique de réduction de dimension. Applications :

- Visualisation des données en 2D/3D
- Compression de l'information
- Détection des variables les plus importantes

Clustering

- K-Means
- DBSCAN
- Clustering hiérarchique

Permet de segmenter :

- Clients
- Sols agricoles
- Parcelles

06 Feature Engineering

Étape essentielle avant le Machine Learning : elle consiste à créer, transformer ou recombinaer des variables pour améliorer la qualité de l'information fournie au modèle.

Création de variables

```
df["Rendement_par_Hectare"] = df["Production"] / df["Surface"]
```

Transformation — Encodage des variables qualitatives

```
pd.get_dummies(df)
```

Normalisation (0 à 1)

```
from sklearn.preprocessing import MinMaxScaler
```

Standardisation (centrage autour de 0)

```
from sklearn.preprocessing import StandardScaler
```


07 Sélection des variables

Objectifs :

- Réduire le bruit dans les données
- Améliorer les performances du modèle

Corrélation

```
df.corr()
```

SelectKBest

```
from sklearn.feature_selection import SelectKBest
```

Importance des variables

```
RandomForest
```

08 Modélisation (Machine Learning)

Cette étape est totalement absente d'un plan EDA classique : elle marque le passage de l'analyse descriptive au Machine Learning.

Découpage des données

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y)
```

Régression

Prédire une valeur numérique.

Exemples

- Prix d'une maison
- Rendement agricole

Algorithmes

- Régression linéaire
- Random Forest Regressor
- XGBoost

Classification

Prédire une catégorie.

Exemples

- Sol fertile ou non
- Client fidèle ou non

Algorithmes

- Logistic Regression
- Decision Tree
- Random Forest
- SVM

Clustering (sans variable cible)

Exemples

- Typologie des sols
- Segmentation des agriculteurs

09 Évaluation du modèle

Étape souvent oubliée mais indispensable pour valider la fiabilité du modèle avant son utilisation.

Régression

- MAE — Mean Absolute Error
- MSE — Mean Squared Error
- RMSE — Root Mean Squared Error
- R^2 — Coefficient de détermination

Classification

- Accuracy
- Precision
- Recall
- F1-Score

Matrice de confusion

```
from sklearn.metrics import confusion_matrix
```

10 Interprétation du modèle

Comprendre pourquoi le modèle prend ses décisions.

Importance des variables

```
model.feature_importances_
```

SHAP

Très utilisé aujourd'hui pour expliquer :

- Pourquoi une prédiction a été faite
- Quels facteurs influencent le résultat

11 Visualisation et Reporting

Cette étape consiste à créer :

- Dashboards
- Rapports
- Présentations

Outils

Catégorie	Outils
Visualisation Python	Matplotlib, Seaborn, Plotly
Business Intelligence	Power BI, Tableau
Applications web data	Streamlit, Dash

12 Déploiement (si projet IA)

Mettre le modèle en production.

Outils

- Flask
- FastAPI
- Streamlit
- Docker

Exemple

Système de recommandation agricole basé sur les données des capteurs de sol : le modèle entraîné est exposé via une API (FastAPI), conteneurisé avec Docker, et interrogé en temps réel par les capteurs IoT déployés sur les parcelles.

13 Monitoring et Maintenance

Après le déploiement, plusieurs actions doivent être mises en place :

- Surveillance des performances du modèle en production
- Réentraînement périodique du modèle
- Détection de dérive des données (Data Drift)

*Pour une **formation Data Analyst**, les étapes 1 à 11 sont généralement suffisantes. Pour une **formation Data Scientist / Machine Learning Engineer**, les étapes 12 et 13 deviennent indispensables.*

— Résumé du pipeline complet

Le schéma ci-dessous synthétise les 13 étapes d'un projet d'analyse de données, de la compréhension du besoin métier jusqu'au monitoring en production.

